

belief への補助損失（次観測予測・報酬予測）の定義 — 本実装の数式

Belief-Score-Based-Model 実装ノート

2026-09-07

1 記号

- 時刻 t の粒子集合 $X_t = \{x_{t,k}\}_{k=1}^K$, $x_{t,k} \in \mathbb{R}^{d_s}$ ($K = 16$, $d_s = 2$). 予測網には粒子の位置のみを渡し、スコアベクトル $\nabla E(x_{t,k})$ は渡さない.
- 時刻 t に実行した行動の特徴 $a_t \in \mathbb{R}^{d_a}$ (離散なら one-hot, 連続なら行動そのもの). rollout では「時刻 $t+1$ の直前行動」として保存されている.
- 次の観測 $o_{t+1} \in \mathbb{R}^{d_o}$ (Mountain Hike では $d_o = 2$), 時刻 t の報酬 $r_t \in \mathbb{R}$.
- 観測予測網 $h_\phi: (x, a) \mapsto (\mu, \log \sigma) \in \mathbb{R}^{d_o} \times \mathbb{R}^{d_o}$ (MLP, 隠れ層 [64], 実装名 ObservationPredictor), $\log \sigma$ は $[-4, 3]$ にクランプ. 報酬予測網 $h_\psi^r: (x, a) \mapsto (\mu^r, \log \sigma^r) \in \mathbb{R} \times \mathbb{R}$ (RewardPredictor). これらは補助損失専用の網で, belief のエネルギー網 g_0, f, u や v2g の遷移ドリフト g とは別物である.
- マスク $m_t = \mathbb{1}[\text{step } t \text{ がエピソード終端でない}]$. 終端の次は別エピソードなので除外する.

2 次観測の予測尤度

粒子ごとの対角ガウスを等重み $1/K$ で混合した予測分布を用いる:

$$q_\phi(o_{t+1} | X_t, a_t) = \frac{1}{K} \sum_{k=1}^K \prod_{j=1}^{d_o} \mathcal{N}(o_{t+1,j}; \mu_j(x_{t,k}, a_t), \sigma_j^2(x_{t,k}, a_t)). \quad (1)$$

数値的には log-sum-exp で評価する:

$$\log q_\phi(o_{t+1} | X_t, a_t) = \text{LSE}_k \left[\sum_{j=1}^{d_o} \left(-\frac{1}{2} \left(\frac{o_{t+1,j} - \mu_j(x_{t,k}, a_t)}{\sigma_j(x_{t,k}, a_t)} \right)^2 - \log \sigma_j(x_{t,k}, a_t) - \frac{1}{2} \log 2\pi \right) \right] - \log K. \quad (2)$$

損失はマスク付き平均の負の対数尤度:

$$\mathcal{L}_{\text{obs}} = - \frac{\sum_t m_t \log q_\phi(o_{t+1} | X_t, a_t)}{\max(1, \sum_t m_t)}. \quad (3)$$

3 報酬の予測尤度（同形のスカラー版）

$$\mathcal{L}_{\text{rew}} = - \frac{\sum_t m_t \log \frac{1}{K} \sum_{k=1}^K \mathcal{N}(r_t; \mu^r(x_{t,k}, a_t), \sigma^r(x_{t,k}, a_t)^2)}{\max(1, \sum_t m_t)}. \quad (4)$$

報酬は時刻 t の状態と行動で決まるので, 時刻 t の粒子と a_t を条件にする (観測側は $t+1$ の観測を予測する点異なる).

4 全体の損失と勾配の流れ

$$\mathcal{L} = \mathcal{L}_{\text{PPO}} + c_V \mathcal{L}_{\text{value}} - c_H H + c_{\text{obs}} \mathcal{L}_{\text{obs}} + c_{\text{rew}} \mathcal{L}_{\text{rew}}, \quad c_{\text{obs}} = c_{\text{rew}} = 1 \text{ (v2)}. \quad (5)$$

$\mathcal{L}_{\text{obs}}, \mathcal{L}_{\text{rew}}$ の勾配は予測網 ϕ, ψ と、粒子 $x_{t,k}$ を経由して ULA 連鎖（再パラメータ化して再生）→ エネルギー網 g_0, f, u , 観測アンカー, 遷移ドリフト g へ流れる. 方策ヘッドと価値ヘッドは q_ϕ, q_ψ の出力を一切使わない（純粋な補助損失）.

5 注意点

1. 復元対象は現在の o_t ではなく**次の** o_{t+1} . 現在観測の復元は粒子を「現在観測の写し」にするだけで時間統合の圧力にならないため, 1 ステップ先の予測（予測十分性）にしている.
2. 等重み $1/K$ は ULA サンプルに重みがないことの反映. DVRL の ELBO と異なり遷移モデルの KL 項はない.
3. Mountain Hike では $o_{t+1} = s_{t+1} + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, 3^2 I)$ なので, 粒子が真の位置を完全に持っていたとしても最良の予測は $\sigma \approx 3$ にとどまり, 観測側の信号は弱い（1 ステップの移動 ≤ 0.5 に対しノイズ 3）. 報酬側は地形が位置の決定的関数なので粒子を位置に固定する力が強い.
4. 情報量の観点では, $H(o_{t+1} | a_t) - \mathcal{L}_{\text{obs}}$ が $I(X_t; o_{t+1} | a_t)$ の変分下界（Barber–Agakov）になっており, 補助損失の最小化は「粒子が次観測について持つ情報量」の下界の最大化である.